

ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG DỰ BÁO ROA VÀ ROE CỦA DOANH NGHIỆP BÁN LẺ TẠI VIỆT NAM

Đỗ Quang Hưng^{1*}

¹ Khoa Tài chính Kế toán 1, Học viện Công nghệ Bưu chính Viễn thông, Hà Nội

Ngày nhận bài: 16/04/2025; Ngày chỉnh sửa: 01/05/2025; Ngày duyệt đăng: 09/05/2025

DOI: <https://doi.org/10.59775/1859-3968.268>

Tóm tắt

Nghiên cứu này nhằm xây dựng mô hình dự báo hiệu suất tài chính của các doanh nghiệp bán lẻ tại Việt Nam thông qua hai chỉ số quan trọng là ROA và ROE, bằng cách ứng dụng các mô hình trí tuệ nhân tạo (AI) gồm Random Forest, XGBoost và MLP. Dữ liệu sử dụng bao gồm báo cáo tài chính của 12 doanh nghiệp bán lẻ giai đoạn 2010-2024 kết hợp với các biến kinh tế vĩ mô như CPI, tỷ giá, giá vàng và giá dầu. Kết quả thực nghiệm cho thấy mô hình Random Forest đạt độ chính xác cao nhất, phản ánh hiệu quả vượt trội trong việc dự báo các chỉ số tài chính. Nghiên cứu này khẳng định tiềm năng ứng dụng AI trong quản trị tài chính doanh nghiệp, đồng thời cung cấp bằng chứng thực nghiệm quan trọng cho các doanh nghiệp, nhà đầu tư và nhà hoạch định chính sách trong việc nâng cao năng lực dự báo và ra quyết định.

Từ khóa: Trí tuệ nhân tạo, học máy, ROA, ROE, doanh nghiệp bán lẻ.

1. Đặt vấn đề

Hiệu quả tài chính là yếu tố then chốt quyết định sự thành công và bền vững của doanh nghiệp, đặc biệt trong ngành bán lẻ - lĩnh vực cạnh tranh cao và chịu tác động mạnh từ các biến động kinh tế vĩ mô. Hai chỉ số phổ biến để đánh giá hiệu quả này là ROA (Return on Assets) và ROE (Return on Equity), lần lượt phản ánh khả năng sinh lời từ tài sản và vốn chủ sở hữu. Việc dự báo chính xác ROA và ROE giúp doanh nghiệp điều chỉnh chiến lược tài chính, đồng thời hỗ trợ nhà quản lý và nhà đầu tư ra quyết định hiệu quả hơn.

Các phương pháp dự báo truyền thống như hồi quy tuyến tính, mô hình chuỗi thời gian hoặc phân tích chỉ số kế toán thường gặp hạn chế trong việc xử lý dữ liệu tài chính phi tuyến và biến động. Trong khi đó, sự phát triển của Trí tuệ nhân tạo (AI) và Học máy (ML) mang lại hướng tiếp cận mới, cho phép khai thác dữ liệu lớn và phát hiện các mô hình phức tạp. Nhiều nghiên cứu quốc tế như của Kayakus [1], Tutcu [2] và He [6] đã chứng minh tính hiệu quả của các mô hình AI/ML trong dự báo ROA và ROE.

Nghiên cứu này hướng đến việc xây dựng mô hình AI/ML để dự báo ROA và ROE cho

các doanh nghiệp bán lẻ tại Việt Nam, sử dụng dữ liệu tài chính giai đoạn 2010-2024 kết hợp với các biến vĩ mô như CPI, tỷ giá, giá vàng, VN-Index và giá dầu. Qua việc so sánh hiệu suất giữa các mô hình, nghiên cứu nhằm xác định mô hình dự báo tối ưu và các yếu tố ảnh hưởng chính đến hiệu quả tài chính trong lĩnh vực bán lẻ.

2. Tổng quan nghiên cứu

ROA (Return on Assets) và ROE (Return on Equity) là hai chỉ số quan trọng phản ánh hiệu quả sử dụng tài sản và vốn chủ sở hữu của doanh nghiệp. Nhiều nghiên cứu cho thấy chúng bị ảnh hưởng bởi cả yếu tố nội tại lẫn vĩ mô. Trước đây, các mô hình dự báo thường sử dụng phương pháp truyền thống như hồi quy tuyến tính, ARIMA, VAR hay Fama-French - tuy dễ triển khai nhưng hạn chế khi xử lý dữ liệu phi tuyến hoặc biến động mạnh.

Trong bối cảnh thị trường ngày càng phức tạp, các mô hình AI và học máy (ML) đã được nghiên cứu nhằm cải thiện hiệu quả dự báo tài chính. Trên thế giới, Kayakus và cộng sự [1] sử dụng ANN, MLR và SVR để dự báo ROA và ROE ngành sắt thép, trong khi Tutcu và cộng sự [2] áp dụng ML cho doanh nghiệp công nghệ Thổ Nhĩ Kỳ. He và cộng sự [6] đề xuất mô hình học sâu tổng hợp mang lại kết quả vượt trội, còn Das và cộng sự [4] cho thấy tiềm năng của XGBoost trong lĩnh vực ngân hàng.

Tại Việt Nam, ứng dụng AI/ML trong tài chính còn mới mẻ. Nguyễn Phát Đạt và cộng sự [7] áp dụng ML/DL trong phân tích tín dụng cá nhân, còn Nguyễn Minh Nhật và Ngô Hoàng Khánh Duy [8] phát triển mô hình dự báo rủi ro vỡ nợ cho doanh nghiệp vừa và nhỏ. Tuy nhiên, ít nghiên cứu tập trung vào lĩnh vực bán lẻ.

Tổng quan cho thấy có khoảng trống trong việc áp dụng AI/ML để dự báo ROA và ROE của doanh nghiệp bán lẻ tại Việt Nam. Trong bối cảnh ngành bán lẻ chịu tác động mạnh từ biến động kinh tế, việc xây dựng mô hình dự báo bằng AI/ML là cần thiết nhằm hỗ trợ ra quyết định chính xác hơn. Nghiên cứu này nhằm lấp đầy khoảng trống đó và cung cấp bằng chứng thực nghiệm trong bối cảnh Việt Nam.

3. Phương pháp nghiên cứu

3.1. Dữ liệu nghiên cứu

Việc lựa chọn các biến độc lập được dựa trên cả cơ sở lý thuyết và tổng quan nghiên cứu đã trình bày ở phần trước. Theo các lý thuyết về hiệu quả tài chính doanh nghiệp và các nghiên cứu gần đây [1, 2, 7], ROA và ROE chịu tác động của cả yếu tố nội tại như quy mô tài sản, khả năng thanh khoản, mức độ sử dụng đòn bẩy tài chính, vòng quay tài sản, cũng như yếu tố bên ngoài như lạm phát, tỷ giá, giá vàng và giá dầu. Đây cũng là cơ sở để hình thành bộ biến đầu vào cho mô hình dự báo.

Trên cơ sở đó, nghiên cứu đưa ra các giả định phân tích như sau: (1) Các yếu tố tài chính nội tại có mối quan hệ phi tuyến đáng kể với ROA và ROE; (2) Các yếu tố kinh tế vĩ mô có thể ảnh hưởng đến khả năng sinh lời của doanh nghiệp bán lẻ, mặc dù mức độ tác động có thể không mạnh như yếu tố nội tại; (3) Các mô hình học máy, với khả năng nhận diện quan hệ phức tạp trong dữ liệu, có thể mang lại hiệu quả dự báo cao hơn so với các phương pháp truyền thống.

Dữ liệu sử dụng trong nghiên cứu được thu thập từ nhiều nguồn khác nhau. Các biến tài chính của doanh nghiệp được lấy từ báo cáo tài chính của các doanh nghiệp bán lẻ tại Việt Nam. Dữ liệu về các biến kinh tế vĩ mô được thu thập từ Tổng cục Thống kê Việt Nam và

các trang web tài chính. Nghiên cứu này sử dụng Return on Assets (ROA) và Return on Equities (ROE) làm biến phụ thuộc. Các biến độc lập bao gồm: Total Assets: Tổng tài sản của doanh nghiệp; Current Ratio: Tỷ số thanh khoản hiện hành, phản ánh khả năng thanh toán ngắn hạn; Leverage Ratio: Tỷ lệ đòn bẩy tài chính, thể hiện mức độ sử dụng nợ trong cấu trúc vốn; Assets Turnover: Vòng quay tài sản, đo lường hiệu suất sử dụng tài sản để tạo doanh thu; Working Capital: Vốn lưu động, đại diện cho khả năng đáp ứng nghĩa vụ tài chính ngắn hạn; USD-VND Exchange Rate: Tỷ giá hối đoái giữa đồng USD và

VND; Gold Price: Giá vàng thế giới, có thể ảnh hưởng đến thị trường tài chính; Crude WTI Oil Price: Giá dầu thô WTI, đại diện cho chi phí nguyên liệu đầu vào; Brent Oil Price: Giá dầu thô Brent, chỉ báo quan trọng của thị trường năng lượng; CPI (Consumer Price Index): Chỉ số giá tiêu dùng, thể hiện lạm phát trong nền kinh tế.

Dữ liệu được thu thập trong giai đoạn 2010-2024, cung cấp thông tin theo chuỗi thời gian nhằm đảm bảo tính toàn diện và phản ánh chính xác xu hướng của các biến nghiên cứu. Danh sách các doanh nghiệp trong nghiên cứu được trình bày tại Bảng 1.

Bảng 1. Danh sách công ty nhóm ngành bán lẻ

Mã công ty	Tên công ty	Sàn niêm yết
FRT	Công ty Cổ phần Bán lẻ Kỹ thuật số FPT	HOSE
PNJ	Công ty Cổ phần Vàng bạc Đá quý Phú Nhuận	HOSE
MSN	Công ty Cổ phần Tập đoàn Masan	HOSE
MWG	Công ty Cổ phần Đầu tư Thế giới Di động	HOSE
DGW	Công ty Cổ phần Thế Giới Số	HOSE
BTT	Công ty Cổ phần Thương mại Dịch vụ Bến Thành	HOSE
CMV	Công ty Cổ phần Thương nghiệp Cà Mau	HOSE
CTF	Công ty Cổ phần City Auto	HOSE
HAX	Công ty Cổ phần Dịch vụ Ô tô Hàng Xanh	HOSE
HTC	Công ty Cổ phần Thương mại Hóc Môn	HNX
TMC	Công ty Cổ phần Thương mại Xuất nhập khẩu Thủ Đức	HNX
MCH	Công ty Cổ phần Hàng tiêu dùng Masan	UPCOM

Nguồn: Tổng hợp của tác giả.

Để đảm bảo tính đại diện cho toàn ngành, các doanh nghiệp bán lẻ trong mẫu nghiên cứu được lựa chọn theo tiêu chí sau: (1) doanh nghiệp thuộc nhóm ngành bán lẻ theo phân ngành cấp 4 (mã ngành G₄₇) trong hệ thống phân ngành kinh tế Việt Nam; (2) có dữ liệu tài chính đầy đủ và liên tục từ năm 2010 đến 2024; (3) đang niêm yết trên các sàn giao dịch chứng khoán HOSE, HNX hoặc UPCOM để đảm bảo độ tin cậy và minh bạch thông tin. Tổng cộng có 12 doanh

nh nghiệp được chọn, bao gồm các đại diện lớn trong lĩnh vực bán lẻ hàng tiêu dùng, điện máy, trang sức, ô tô và thương mại tổng hợp. Đây là các doanh nghiệp có quy mô lớn, hoạt động đa dạng và có ảnh hưởng đáng kể đến thị trường bán lẻ trong nước. Do đó, mẫu nghiên cứu được xem là có tính đại diện cao cho ngành bán lẻ niêm yết tại Việt Nam, đặc biệt là nhóm doanh nghiệp có mức độ công khai thông tin tài chính rõ ràng và minh bạch.

3.2. Phương pháp tiền xử lý dữ liệu

Quá trình tiền xử lý dữ liệu đóng vai trò quan trọng trong việc đảm bảo chất lượng dữ liệu đầu vào cho mô hình dự báo ROA và ROE. Trong nghiên cứu này, dữ liệu được tiền xử lý qua các bước chính sau:

- Loại bỏ giá trị ngoại lai bằng phương pháp IQR.

- Chuẩn hóa dữ liệu bằng Min-Max Scaling.

3.3. Mô hình dự báo

Trong nghiên cứu, ba mô hình học máy và trí tuệ nhân tạo được sử dụng để dự báo ROA và ROE của doanh nghiệp bán lẻ tại Việt Nam, bao gồm:

Random Forest Regressor: Random Forest là một mô hình ensemble sử dụng nhiều cây quyết định để dự báo giá trị mục tiêu. Mô hình này giúp giảm phương sai và cải thiện độ chính xác bằng cách kết hợp kết quả từ nhiều cây riêng lẻ. Random Forest hoạt động tốt với dữ liệu phi tuyến tính và có khả năng xử lý dữ liệu nhiều chiều [9].

XGBoost Regressor: XGBoost là một thuật toán boosting mạnh mẽ, được tối ưu hóa để hoạt động hiệu quả với dữ liệu lớn và có thể giảm thiểu lỗi tổng quát hóa. XGBoost sử dụng cây quyết định để tạo ra dự báo và cải thiện dần kết quả thông qua quá trình học có trọng số [10].

MLP (Neural Network): Mô hình MLP (Multilayer Perceptron) là một dạng mạng nơ-ron nhân tạo có nhiều lớp ẩn, giúp học các đặc trưng phức tạp từ dữ liệu. MLP hoạt động tốt với dữ liệu phi tuyến và có khả năng dự báo chính xác nếu được huấn luyện đúng cách [11].

Các bước xây dựng mô hình dự báo được trình bày trong Hình 1. Để đánh giá hiệu suất dự báo của các mô hình, nghiên cứu này sử dụng các chỉ tiêu phổ biến như sau:

- Căn của sai số bình phương trung bình (Root Mean Squared Error - RMSE):

$$RMSE = \sqrt{\frac{1}{m} \sum_{k=1}^m (t_k - y_k)^2} \quad (1)$$

Với t_k là giá trị mong muốn, y_k là giá trị dự báo của mô hình, m là tổng số mẫu.

- Sai số tương đối trung bình (Mean Absolute Percent Error - MAPE):

$$MAPE = \frac{1}{m} \sum_{k=1}^m \left| \frac{t_k - y_k}{t_k} \right| \quad (2)$$

- Sai số tuyệt đối trung bình MAE (Mean Absolute Error):

$$MAE = \frac{1}{m} \sum_{k=1}^m |t_k - y_k| \quad (3)$$

- Hệ số tương quan Pearson :

$$R = \frac{\sum_{k=1}^m (t_k - \bar{t})(y_k - \bar{y})}{\sqrt{\sum_{k=1}^m (t_k - \bar{t})^2 \cdot \sum_{k=1}^m (y_k - \bar{y})^2}} \quad (4)$$

$$\text{Với } \bar{t} = \frac{1}{m} \sum_{k=1}^m t_k \text{ và } \bar{y} = \frac{1}{m} \sum_{k=1}^m y_k.$$


- Theil's U: Hệ số này được sử dụng để so sánh các mô hình dự báo, công thức như sau:

$$U = \frac{\sqrt{\sum_{k=1}^m (t_k - y_k)^2}}{\sum_{k=1}^m t_k^2 + \sum_{k=1}^m y_k^2} \quad (5)$$

Giá trị U nằm trong khoảng từ 0 đến 1, U càng tiến về 0 thì mô hình dự báo càng chính xác.

Có giá trị từ -1 đến 1, được dùng để đo lường mức độ phụ thuộc tuyến tính giữa giá trị thực tế và giá trị dự báo. Hệ số tương quan bằng 0 (hay gần 0) có nghĩa là không có liên hệ giữa hai biến số; ngược lại nếu bằng -1 hay 1 có nghĩa là giữa giá trị thực tế và giá trị dự báo có một mối liên hệ tuyệt đối. Nếu có nghĩa là khi tăng cao thì giảm và ngược lại; nếu có nghĩa là khi tăng cao thì cũng tăng, và khi giảm cao thì cũng giảm theo.

Trong các chỉ tiêu đánh giá nêu trên, giá trị RMSE, MAE và MAPE càng nhỏ thì mô hình dự báo càng chính xác, vì chúng phản ánh mức độ sai lệch giữa giá trị thực tế và giá trị dự báo. Đặc biệt, MAPE cho biết tỷ lệ sai số dự báo trung bình so với thực tế (tính theo phần trăm), do đó rất hữu ích trong so sánh hiệu suất giữa các mô hình. Ngược lại, hệ số tương quan Pearson (R) càng gần 1 thì mô hình càng phản ánh tốt mối quan hệ tuyến tính giữa giá trị dự báo và thực tế, cho thấy khả năng tái hiện xu hướng dữ liệu của mô hình là cao. Theil's U càng gần 0 thì mô hình càng có độ chính xác cao, cho thấy hiệu suất dự báo tốt hơn so với dự báo bằng trung bình lịch sử.



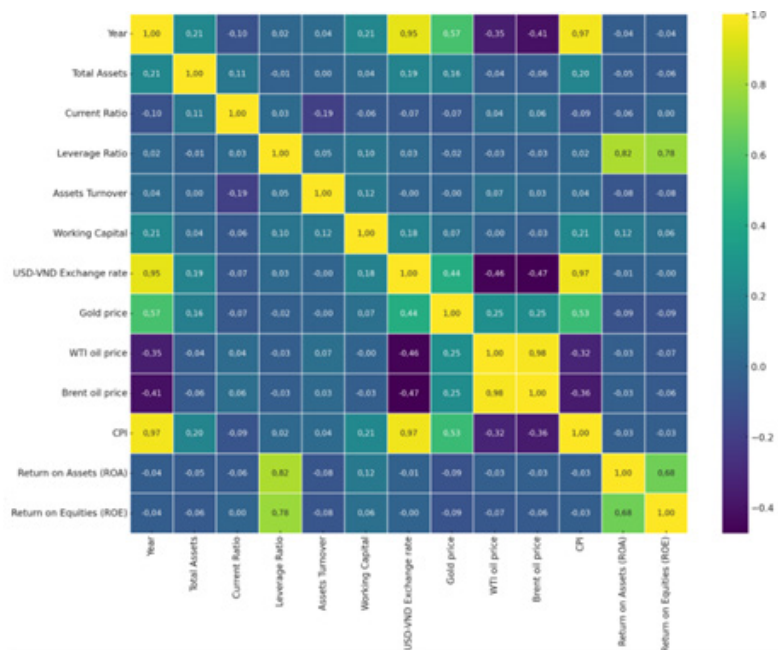
Hình 1. Các bước xây dựng mô hình dự báo

Nguồn: Tác giả.

4. Kết quả nghiên cứu và thảo luận

4.1. Mô tả dữ liệu

Dựa vào Hình 2, có một số nhận xét về biểu đồ heatmap thể hiện ma trận tương quan giữa các biến trong dữ liệu như sau: Mỗi quan hệ giữa các biến phụ thuộc (ROA, ROE) và các biến độc lập Leverage Ratio có tương quan dương mạnh với ROA (0,82) và ROE (0,78). Điều này cho thấy các doanh nghiệp có tỷ lệ đòn bẩy tài chính cao có xu hướng đạt lợi nhuận cao hơn. Tuy nhiên, điều này cũng có thể phản ánh rủi ro tài chính cao. ROA và ROE có tương quan dương rất mạnh (0,68).



Hình 2. Biểu đồ heatmap thể hiện ma trận tương quan giữa các biến.

Nguồn: Tác giả tính toán.

Điều này hợp lý vì cả hai đều phản ánh khả năng sinh lời của doanh nghiệp, với ROE chịu tác động của đòn bẩy tài chính. Các biến kinh tế vĩ mô như CPI, USD-VND Exchange Rate, Gold Price, WTI Oil Price và Brent Oil Price có tương quan yếu với ROA và ROE. Điều này cho thấy những yếu tố kinh tế vĩ mô có thể có tác động nhưng không phải là yếu tố chính quyết định lợi nhuận doanh nghiệp bán lẻ.

4.2. Kết quả dự báo

Nghiên cứu này áp dụng ba mô hình trí tuệ nhân tạo gồm Random Forest, XGBoost và MLP (Neural Network) để dự báo ROA và ROE của các doanh nghiệp bán lẻ tại Việt Nam. Để đánh giá hiệu suất dự báo của các mô hình, nghiên cứu sử dụng các chỉ số RMSE, MAPE, MAE, hệ số tương quan Pearson (R) và Theil's U.


Bảng 2. Kết quả dự báo ROA

Mô hình	RMSE	MAPE	MAE	Pearson Correlation R	Theil's U
Random Forest	0,0926	73,5290	0,0742	0,9079	0,0929
XGBoost	0,0992	40,2614	0,0735	0,8975	0,1000
MLP (Neural Network)	0,1031	66,2759	0,0830	0,8864	0,1045

Nguồn: Tác giả tính toán.


Kết quả dự báo ROA của ba mô hình được trình bày trong Bảng 2. Mô hình Random Forest có độ chính xác cao nhất với RMSE = 0,0926, MAE = 0,0742 và hệ số tương quan R = 0,9079. XGBoost có RMSE = 0,0992 và hệ số tương quan R = 0,8975, cho thấy

hiệu suất kém hơn Random Forest nhưng vẫn tương đối tốt. Mô hình MLP có RMSE cao nhất (0,1031), MAE lớn nhất (0,0830) và hệ số tương quan thấp nhất (0,8864), cho thấy khả năng dự báo thấp hơn hai mô hình còn lại.




Hình 3. Giá trị thực tế và dự báo ROA của Random Forest

Nguồn: Tác giả tính toán.



Hình 4. Giá trị thực tế và dự báo ROA của XGBoost

Nguồn: Tác giả tính toán.



Hình 5. Giá trị thực tế và dự báo ROA của MLP (Neural Network)

Nguồn: Tác giả tính toán.


Hình 3, Hình 4 và Hình 5 trực quan hóa sự so sánh giữa giá trị thực tế và giá trị dự báo của ROA. Hình 3 cho thấy mô hình Random Forest tái hiện tốt xu hướng của dữ liệu thực tế, với các điểm dữ liệu phân

bố gần với đường $y = x$. Hình 4 và Hình 5 thể hiện rằng XGBoost và MLP cũng có khả năng dự báo khá tốt nhưng độ chênh lệch giữa giá trị thực tế và giá trị dự báo cao hơn so với Random Forest.

Bảng 3. Kết quả dự báo ROE


Mô hình	RMSE	MAPE	MAE	Pearson Correlation R	Theil's U
Random Forest	0,0811	18,8283	0,0677	0,9526	0,0791
XGBoost	0,0920	17,5681	0,0782	0,9387	0,0902
MLP (Neural Network)	0,1068	21,1781	0,0857	0,9052	0,1051

Nguồn: Tác giả tính toán.




Hình 6. Giá trị thực tế và dự báo ROE của Random Forest

Nguồn: Tác giả tính toán.



Hình 7. Giá trị thực tế và dự báo ROE của XGBoost

Nguồn: Tác giả tính toán.



Hình 8. Giá trị thực tế và dự báo ROE của MLP (Neural Network)

Nguồn: Tác giả tính toán.

Bảng 3 trình bày kết quả dự báo ROE. Trong ba mô hình, Random Forest tiếp tục thể hiện độ chính xác cao nhất với $RMSE = 0,0811$, $MAE = 0,0677$ và hệ số tương quan $R = 0,9526$. Mô hình XGBoost có $RMSE = 0,0920$ và $R = 0,9387$, cho thấy độ chính xác kém hơn một chút so với Random Forest. MLP có $RMSE$ cao nhất ($0,1068$), hệ số tương quan thấp nhất ($0,9052$) và sai số cao hơn so với hai mô hình còn lại.

Hình 6, Hình 7 và Hình 8 minh họa sự so sánh giữa giá trị thực tế và dự báo ROE của ba mô hình. Hình 6 cho thấy, mô hình Random Forest có sự khớp nối tốt nhất với giá trị thực tế. Hình 7 và Hình 8 thể hiện rằng XGBoost và MLP có xu hướng dự báo kém chính xác hơn, với sự chênh lệch lớn hơn giữa giá trị thực tế và giá trị dự báo.

Tóm lại, trong cả hai bài toán dự báo ROA và ROE, Random Forest cho kết quả tốt nhất với sai số thấp nhất và hệ số tương quan cao nhất, cho thấy mô hình này phù hợp hơn với tập dữ liệu nghiên cứu. XGBoost cũng cho kết quả khả quan, nhưng không chính xác bằng Random Forest. Mô hình MLP có độ chính xác kém nhất trong ba mô hình, có thể do dữ liệu tài chính có tính tuyến tính tương đối cao, làm giảm lợi thế của mạng nơ-ron nhân tạo so với các mô hình cây quyết định như Random Forest và XGBoost.

Kết quả này nhấn mạnh rằng các mô hình dự báo dựa trên cây quyết định (ensemble learning) như Random Forest và XGBoost có khả năng hoạt động tốt với dữ liệu tài chính của doanh nghiệp bán lẻ tại Việt Nam. Việc lựa chọn mô hình phù hợp sẽ giúp cải thiện độ chính xác của dự báo ROA và ROE, từ đó hỗ trợ doanh nghiệp và nhà đầu tư trong việc ra quyết định tài chính hiệu quả hơn.

5. Kết luận

Nghiên cứu này ứng dụng các mô hình AI gồm Random Forest, XGBoost và MLP để dự báo ROA và ROE của doanh nghiệp bán lẻ tại Việt Nam. Kết quả cho thấy Random Forest cho độ chính xác cao nhất, phản ánh khả năng xử lý dữ liệu phi tuyến tốt hơn so với XGBoost và MLP. XGBoost tuy hiệu quả nhưng chưa vượt qua Random Forest, còn MLP kém chính xác hơn do hạn chế trong việc xử lý dữ liệu tài chính không quá phức tạp.

Kết quả nhấn mạnh tiềm năng lớn của AI trong dự báo tài chính, giúp doanh nghiệp và nhà đầu tư đưa ra quyết định hiệu quả hơn. Một số kiến nghị được đưa ra gồm: (1) Doanh nghiệp nên áp dụng Random Forest để dự báo hiệu suất tài chính, hỗ trợ quản trị tài sản và vốn; (2) Cần tích hợp thêm yếu tố vĩ mô dù tác động không mạnh, nhằm có góc nhìn toàn diện hơn; (3) Phát triển mô hình dự báo nâng cao như LSTM, Transformer hoặc kết hợp AI với phương pháp truyền thống để cải thiện độ chính xác; (4) Đảm bảo chất lượng và cập nhật dữ liệu liên tục để nâng cao hiệu quả dự báo.

Nghiên cứu mang lại nhiều hàm ý thực tiễn. Đối với doanh nghiệp bán lẻ, việc dự báo ROA và ROE bằng AI không chỉ giúp lập kế hoạch tài chính tốt hơn mà còn phát hiện sớm rủi ro, từ đó điều chỉnh chiến lược phù hợp. Các mô hình này cũng có thể tích hợp vào hệ thống quản trị tài chính nội bộ để nâng cao năng lực ra quyết định trong môi trường biến động.

Với cơ quan hoạch định chính sách, kết quả cho thấy tỷ giá, CPI và giá vàng có ảnh hưởng nhất định đến hiệu suất tài chính doanh nghiệp. Do đó, cần xây dựng chính sách kinh tế ổn định, đồng thời phát triển hệ thống dữ liệu tài chính mở và khuyến khích chuyển đổi số trong doanh nghiệp bán lẻ.

Đối với nhà đầu tư, mô hình AI có thể hỗ trợ đánh giá năng lực tài chính doanh nghiệp một cách định lượng và chính xác hơn, đồng thời kết hợp dữ liệu hiện tại và xu hướng biến động vĩ mô vào quá trình ra quyết định đầu tư.

Tuy nhiên, nghiên cứu còn một số hạn chế: chưa xét đến yếu tố phi tài chính như hành vi tiêu dùng và mức độ cạnh tranh; chỉ sử dụng ba mô hình phổ biến, chưa khai thác các phương pháp tiên tiến hơn; và dữ liệu giới hạn trong giai đoạn 2010-2024 trong khi thị trường liên tục thay đổi. Các nghiên cứu tương lai nên mở rộng phạm vi dữ liệu, áp dụng thêm mô hình học máy thời gian thực và tích hợp nhiều yếu tố hơn để nâng cao độ tin cậy và ứng dụng thực tế.

Lời cảm ơn: Tác giả xin trân trọng cảm ơn Học viện Công nghệ Bưu chính Viễn thông đã tài trợ cho đề tài nghiên cứu “Nghiên cứu ứng dụng trí tuệ nhân tạo trong dự báo chỉ số khả năng sinh lời của doanh nghiệp bán lẻ tại Việt Nam” (Mã số: 03-2025-HV-TCKT1), là cơ sở cho việc thực hiện và hoàn thiện bài báo này.

Tài liệu tham khảo

- [1] Kayakus M., Tutcu B., Terzioğlu M., Talaş H. & Ünal Uyar G. F (2023). ROA and ROE forecasting in iron and steel industry using machine learning techniques for sustainable profitability. *Sustainability*, 15(9), 1-14.
- [2] Tutcu B., Kayakuş M., Terzioğlu M., Ünal Uyar G. F., Talaş H. & Yetiz F. (2024). Predicting financial performance in the IT industry with machine learning: ROA and ROE analysis. *Appl Sciences.*, 14(17), 1-16.
- [3] Son P. V. H. & Duong L. T. (2024). Research on applying machine learning models to predict and assess return on assets (ROA). *Asian Journal of Civil Engineering*, 25(5), 4269-4279.
- [4] Das A., De S., Mukherjee T., Dey M. & Das Ghosh K. (2024). Forecasting bank ROE with gradient boosting: a machine learning approach. *Proceedings of the 5th International Conference on Data Intelligence and Cognitive Informatics (ICDICI)*, 448-452.
- [5] Balci T. & Ogul H. (2021) Predicting bank return on equity (ROE) using neural networks. *Proceedings of the IEEE 19th World Symposium on Applied Machine Intelligence and Informatics (SAMII)*, 279-286.
- [6] He K., Yang Q., Ji L., Pan J. & Zou Y. (2023). Financial time series forecasting with the deep learning ensemble model. *Mathematics*, 11(4), 1054.
- [7] Nguyễn Phát Đạt, Hồ Mai Minh Nhật, Trương Công Vinh, Lê Quang Chấn Phong & Lê Hoàng Sứ (2025). Ứng dụng học máy và học sâu trong nghiên cứu tài chính: Một nghiên cứu về dự báo khả năng hoàn trả khoản vay của khách hàng. *Tạp chí Khoa học Đại học Mở Thành phố Hồ Chí Minh - Kinh tế và Quản trị kinh doanh*, 20(1), 35-53.
- [8] Nguyễn Minh Nhật & Ngô Hoàng Khánh Duy (2024). Dự báo khả năng vỡ nợ của doanh nghiệp nhỏ và vừa tại Việt Nam: Nghiên cứu trên các mô hình học máy. *Tạp chí Kinh tế - Luật & Ngân hàng*, 266, 51-64.
- [9] Iranzad R. & Liu X. (2024). A review of random forest-based feature selection methods for data science education and applications. *International Journal of Data Science and Analytics*. 2024, 1-15.
- [10] Liu X, Hu Y, Li X, Du R, Xiang Y, Zhang F. (2024). An interpretable model for salinity inversion assessment of the South Bank of the Yellow River based on Optuna hyperparameter optimization and XGBoost. *Agronomy*, 15(18), 1-19.
- [11] Almahadeen L., AlMahadin G., Santosh K., Aarif M., Deb P., Syamala M. & Bala B. K. (2024). Enhancing threat detection in financial cyber security through auto encoder-MLP hybrid models. *International Journal of Advanced Computer Science and Applications*, 15(4), 924-933.

APPLICATION OF ARTIFICIAL INTELLIGENCE IN FORECASTING ROA AND ROE OF RETAIL ENTERPRISES IN VIETNAM

Do Quang Hung¹

¹*Faculty of Finance and Accounting 1,
Posts and Telecommunications Institute of Technology, Hanoi*

Abstract

This study aims to develop forecasting models for the financial performance of retail enterprises in Vietnam by predicting two key indicators: ROA and ROE, using artificial intelligence (AI) models, including Random Forest, XGBoost, and MLP. The research employs financial data from 12 retail companies from 2010 to 2024, combined with macroeconomic variables such as CPI, exchange rates, gold prices and oil prices. Experimental results show that the Random Forest model delivers the highest forecasting accuracy, highlighting its superior performance in financial prediction tasks. The findings emphasize the potential of AI in corporate financial management and offer practical implications for enterprises, investors, and policymakers in enhancing forecasting capabilities and decision-making processes.

Keywords: *Artificial intelligence, machine learning, ROA, ROE, retail enterprises.*